

Estadística descriptiva a través de ejemplos: *Plantago lanceolata*

Martina Fischetti

Material complementario para la asignatura Estadística Aplicada a la Biología del Grado en Biología.

Este material se pone a disposición de los estudiantes de forma gratuita a través de la plataforma de enseñanza virtual de la asignatura y también está disponible públicamente en el repositorio de GitHub de la autora.

Este material está disponible gratuitamente para su uso con fines educativos y se distribuye bajo la licencia Creative Commons CC BY-NC-ND 4.0. Se permite su descarga y distribución siempre que se cite la autoría, no se modifique su contenido y no se utilice con fines comerciales.

Índice

1. Introducción	2
2. Los datos	3
2.0.1. Código en R	5
3. Distribuciones de Frecuencia	5
3.1. Número de hojas (variable discreta)	5
3.1.1. Código en R	6
3.2. Altura (variable continua)	6
3.2.1. Código en R	6
4. Representaciones gráficas según el tipo de dato	6
4.1. Datos cuantitativos discretos: diagrama de barras y polígono de frecuencias . . .	6
4.1.1. Código en R	7
4.1.2. Código en R	8
4.2. Continuas: histograma y polígono de frecuencias	8
4.2.1. Código en R	10
4.2.2. Código en R	11
4.2.3. Un ejemplo con intervalos de diferente amplitud	11
4.2.4. Código en R	13
4.3. Cualitativas: diagrama de rectángulos y diagrama de sectores	13
4.3.1. Código en R	14
5. Medidas de localización y de dispersión	16
5.1. Número de hojas	16
5.2. Interpretación	16
5.2.1. Código en R	17
6. Diagrama de caja y bigotes (o boxplot)	18
6.0.1. Código en R	19

7. Barras de error	19
7.0.1. Código en R	20
7.1. Entropía e índice de diversidad [Complemento]	20
7.1.1. Código en R	20
8. Medidas de forma	21
8.1. Simetria (skewness)	21
8.1.1. Código en R	21
8.1.2. Código en R	22
8.2. Curtosis	23
8.2.1. Código en R	23
9. Análisis de relaciones entre dos características	24
9.1. Relación entre el color de las hojas y el hábitat	24
9.1.1. Código en R	25
9.1.2. Análisis de distribuciones condicionadas	25
9.1.3. Código en R	26
9.2. Relación entre la altura (agrupada) y el numero de hojas	26
9.2.1. Código en R	26
10. Visualización de la relación entre dos características	27
10.0.1. Código en R	27
11. Dependencia funcional e Independencia	28
11.1. Dependencia funcional	28
11.2. Independencia estadística	28
11.2.1. Código en R	29
12. Covarianza	29
12.0.1. Código en R	30
13. Hacemos predicciones: recta de regresión lineal	30
13.0.1. Código en R	32
13.0.2. Código en R	32
A. Cálculo de los coeficientes de la regresión lineal [COMPLEMENTO]	32
A.1. Derivada parcial con respecto a a	32
A.2. Derivada parcial con respecto a b	33
A.3. Resolviendo el sistema	33

1. Introducción

Cuando estudiaba Estadística en la universidad, a menudo me costaba encontrar una aplicación práctica a los conceptos que aprendía. Los libros de teoría suelen estar llenos de ejemplos, pero por lo general son pequeños e independientes entre sí, por lo que me faltaba una visión de conjunto que mostrara cómo todas esas herramientas podían utilizarse para resolver un problema real.

Fue trabajando en la industria cuando me di cuenta de hasta qué punto los conceptos de estadística descriptiva se utilizan constantemente. A menudo los aplicábamos sin recordar la teoría aprendida en la universidad e, incluso, intentando reinventar la rueda. La estadística estaba presente en todas partes: para comprender los datos recopilados, presentarlos de forma

clara a los responsables de la empresa, mejorar experimentos, negociar con proveedores... En definitiva, para aprender a partir de los datos y comunicar los resultados obtenidos.

Hoy vivimos rodeados de datos. Las empresas han comprendido perfectamente su valor y recopilan cantidades cada vez mayores de información. Por ello, especialmente en la actualidad, la estadística descriptiva constituye una herramienta imprescindible para comprender el mundo que nos rodea y para desarrollar nuestro trabajo de forma eficaz, independientemente de la carrera profesional que hayamos elegido.

Imparto Estadística en varias facultades universitarias y decidí escribir este material utilizando un ejemplo biológico, pensado inicialmente para mis estudiantes de Biología. Sin embargo, también quise mostrar que no es necesario ser informático para encontrarse con la estadística en el trabajo cotidiano. Para ello, he construido un caso práctico que integra todos los conceptos de la parte de estadística descriptiva de la asignatura Estadística Aplicada a la Biología de la Universidad de Sevilla, con el objetivo de complementar los apuntes teóricos y facilitar una comprensión más profunda de su aplicación práctica.

Como vivimos en la era del Big Data y de la inteligencia artificial, considero fundamental no solo dominar los conceptos teóricos, sino también saber aplicarlos a conjuntos de datos de tamaño real. En este contexto, la programación se convierte en una herramienta de enorme utilidad. Por este motivo, cada análisis va acompañado de su correspondiente código en R, que el lector podrá adaptar fácilmente a su propio conjunto de datos, ya sea en el ámbito de la biología, la medicina, la informática, la energía o cualquier otra disciplina, y comenzar así a aplicar estos conceptos desde el primer momento.

Por último, hay un tema al que siempre me gusta dedicar una atención especial en mis clases: los modelos de regresión. En este curso básico solo estudiaremos la regresión lineal, pero los modelos predictivos más complejos utilizados en aprendizaje automático siguen exactamente la misma idea fundamental: aprender del pasado para predecir el futuro. Comprender los modelos sencillos que se presentan en este curso es suficiente para empezar a formular preguntas importantes: ¿cómo se recogieron los datos?, ¿son realmente representativos?, ¿qué sesgos pueden contener?

Todos estos modelos aprenden del pasado y realizan predicciones bajo la suposición de que ese pasado seguirá siendo válido en el futuro. Sin embargo, ¿no intentamos precisamente aprender de nuestro pasado para cambiar y mejorar? ¿Cómo afectan estas limitaciones a cuestiones como el racismo, la desigualdad de género u otros problemas sociales que llevamos décadas intentando corregir? Estas preguntas dan lugar a importantes líneas de investigación en las que hoy trabajan especialistas de múltiples disciplinas y, naturalmente, quedan fuera del alcance de este material. No obstante, reflexionar sobre ellas nos ayuda a comprender mejor las tecnologías que utilizamos cada día y a desarrollar una mirada más crítica sobre sus posibilidades y sus limitaciones.

Espero que este material te resulte útil, tanto si eres estudiante como si trabajas en investigación o en la industria y buscas una guía práctica para aprender y aplicar la estadística descriptiva.

2. Los datos

Imaginemos que formamos parte de un equipo de investigación que estudia las características de una planta, *Plantago lanceolata*. Algunos de nuestros compañeros han recopilado diversos datos en el campo. Como sabemos por la teoría —y también podemos intuir fácilmente sin necesidad de ella—, cuanto mayor es la cantidad de datos recopilados, más sólidas y significativas son las conclusiones del estudio.

En este caso hemos creado deliberadamente un conjunto de datos artificial lo suficientemente grande como para justificar el uso de R, pero no tan grande como para impedir que el lector pueda realizar también los cálculos manualmente, si desea practicar las fórmulas presentadas en la parte teórica.

Sin embargo, incluso un ejemplo realista y relativamente pequeño como este nos permite apreciar las ventajas y la eficiencia que ofrece saber utilizar un lenguaje de programación como R.

En este estudio, se analiza el crecimiento de la planta *Plantago lanceolata* bajo dos condiciones ambientales:

- **H1:** pradera húmeda (alta humedad, baja insolación)
- **H2:** pradera seca (baja humedad, alta insolación)

Se registraron las siguientes variables para 30 plantas (15 por hábitat):

- **Hábitat:** variable cualitativa nominal (H1, H2)
- **Altura (mm):** variable cuantitativa continua
- **Número de hojas:** variable cuantitativa discreta
- **Color de hoja:** variable cualitativa nominal (verde oscuro, verde claro, amarillento)

Datos Observados

ID	Hábitat	Altura (mm)	N.º hojas	Color
1	H1	125.0	7	verde claro
2	H1	118.6	11	verde oscuro
3	H1	126.5	7	verde oscuro
4	H1	135.2	6	verde claro
5	H1	117.7	10	verde oscuro
6	H1	117.7	7	verde claro
7	H1	117.9	9	verde oscuro
8	H1	124.7	10	verde claro
9	H1	128.7	9	verde oscuro
10	H1	128.3	10	verde claro
11	H1	120.2	8	verde oscuro
12	H1	128.5	11	verde oscuro
13	H1	120.0	9	verde oscuro
14	H1	122.5	9	verde claro
15	H1	126.0	8	amarillento
16	H2	92.3	4	verde claro
17	H2	101.5	7	amarillento
18	H2	96.7	5	verde claro
19	H2	98.9	6	verde oscuro
20	H2	102.4	5	amarillento
21	H2	109.2	8	verde oscuro
22	H2	88.5	4	amarillento
23	H2	95.1	5	verde claro
24	H2	104.3	6	amarillento
25	H2	99.7	7	verde claro
26	H2	94.8	6	verde claro
27	H2	115.6	9	verde oscuro
28	H2	107.2	8	verde claro
29	H2	98.0	6	amarillento

30	H2	110.3	7	verde oscuro
----	----	-------	---	--------------

Cuadro 1: Tabla con todos los datos de nuestra muestra

Imaginemos que hemos recopilado nuestros datos en formato **CSV**. El formato CSV (por *comma separated values*, es decir, *valores separados por comas*) es un tipo de archivo de texto plano que organiza los datos en filas y columnas, separando cada valor con una coma.

Este formato se utiliza mucho más que Excel, especialmente cuando se trabaja con grandes volúmenes de datos, por las siguientes razones:

- **Ligereza:** Los archivos CSV son mucho más livianos que los de Excel (.xlsx), lo que facilita su manejo y transferencia.
- **Compatibilidad:** Se pueden abrir con casi cualquier editor de texto o software de análisis de datos, como R, Python o incluso bases de datos.
- **Escalabilidad:** Cuando se trata de millones de registros, CSV es más eficiente y menos propenso a errores que Excel.

Para leer nuestros datos en R, utilizamos un código como el siguiente ¹:

2.0.1. Código en R

```
# 1.Read data
df = read.csv("./plantago.csv", stringsAsFactors=TRUE)
df
```

TEMA 1

3. Distribuciones de Frecuencia

A continuación se presentan las tablas de distribución de frecuencias para las variables cuantitativas.

3.1. Número de hojas (variable discreta)

N. hojas	Frec abs (n_i)	Frec acumulada (N_i)	Frec rel (f_i)	Frec rel acumulada (F_i)
4	2	2	0.067	0.067
5	3	5	0.100	0.167
6	5	10	0.167	0.333
7	6	16	0.200	0.533
8	4	20	0.133	0.666
9	5	25	0.167	0.833
10	3	28	0.100	0.933
11	2	30	0.067	1.000
Total	30	—	1.000	—

Cuadro 2: Tabla de frecuencias (número de hojas)

¹En este caso, el archivo plantago.csv se encuentra en la misma carpeta que el código. De lo contrario, el “./” debe ser reemplazado por la ruta del archivo

3.1.1. Código en R

```
hojas = df$N_hojas
#frec abs
fA =table(hojas)
#frec rel
fR = prop.table(fAe)
#frec acumul abs
fAA = cumsum(fA)
#frec acumul rel
fRA = cumsum(fR)
```

3.2. Altura (variable continua)

Se agruparon los datos en intervalos para construir la tabla:

Intervalo (mm)	n_i	N_i	f_i	F_i
(80, 90]	1	1	0.033	0.033
(90, 100]	7	8	0.233	0.267
(100, 110]	5	13	0.167	0.433
(110, 120]	7	20	0.233	0.667
(120, 130]	9	29	0.300	0.967
(130, 140]	1	30	0.033	1
Total	30	—	1.000	—

3.2.1. Código en R

```
altura = df$Altura_mm
extremos_intervalos= c(80, 90, 100, 110, 120, 130, 140)
intervalos = cut (altura, extremos_intervalos )
fAh_interv = table(intervalos)
fAAh_interv = cumsum(fAh_interv)
fRh_interv = prop.table(fAh_interv)
fRAhinterv = cumsum(fRh_interv)

tabla = cbind(fAh_interv, fAAh_interv,fRh_interv, fRAhinterv )
tabla
```

TEMA 2

4. Representaciones gráficas según el tipo de dato

4.1. Datos cuantitativos discretos: diagrama de barras y polígono de frecuencias

Utilizamos el diagrama de barras y el polígono de frecuencias para representar de forma visual y más inmediata la tabla de frecuencias del número de hojas (variable cuantitativa discreta).




Figura 1: Diagrama de barras para el número de hojas.

4.1.1. Código en R

```
plot(fA,  
     type = "h",  
     main = "Número de hojas",  
     xlab = "Número de hojas",  
     ylab = "Frecuencia abs")
```




Figura 2: Polígono de frecuencias para el número de hojas.

4.1.2. Código en R

```
plot(fA,  
     type = "h",  
     main = "Número de hojas",  
     xlab = "Número de hojas",  
     ylab = "Frecuencia abs")  
lines(fA, type = "l", col = "red")
```

4.2. Continuas: histograma y polígono de frecuencias

Ahora nos centramos en la altura, que es una variable cuantitativa continua, la cual hemos dividido en intervalos. En nuestro caso, **los intervalos tienen la misma amplitud**, entonces podemos tomar n_i como la altura de los rectángulos.




Figura 3: Histograma de la altura de las plantas.




Figura 4: Polígono de frecuencias para la altura.

4.2.1. Código en R

```
#para datos cuantitativos continuos agrupados en intervalos iguales:
hist(altura, breaks = extremos_intervalos, col = "lightblue",
     main = "Histograma de altura",
     xlab = "Altura (mm)")

h = hist(altura, breaks = extremos_intervalos, col = "lightblue",
        main = "Histograma de altura",
        xlab = "Altura (mm)")
lines(h$mids, h$counts, type="l")
```

En general, como hemos visto en teoría, en el eje de las abscisas de un histograma se representa **la densidad de frecuencia**. (Recuerda que el caso con todos los intervalos iguales es un caso particular, en el que el eje de las abscisas puede mostrar la frecuencia en lugar de la densidad.) En R puedes visualizar la densidad en el histograma (tanto con intervalos iguales como desiguales) utilizando el parámetro `freq = FALSE`.

Cuando se establece `freq = FALSE`, R representa en la eje de las abscisas las densidades en

lugar de las frecuencias, de modo que el histograma respeta la definición teórica generica incluso cuando los intervalos tienen la misma amplitud ².




Figura 5: Histograma de la altura de las plantas.

Consejo: Para nuestro curso, nunca te equivocas si en los histogramas en R escribes siempre `freq = FALSE`.

4.2.2. Código en R

```
hist(altura, breaks = extremos_intervalos, col = "lightblue", freq = FALSE,
     main = "Histograma de altura",
     xlab = "Altura (mm)")
```

4.2.3. Un ejemplo con intervalos de diferente amplitud

Por ejemplo, si hubiéramos dividido los datos de la altura en los intervalos (irregulares)

(85, 90], (90, 100], (100, 110], (110, 120], (120, 130], (130, 140],

la tabla de frecuencias sería:

Intervalo (mm)	n_i	N_i	f_i	F_i
(85, 90]	1	1	0.033	0.033
(90, 100]	7	8	0.233	0.267
(100, 110]	5	13	0.167	0.433
(110, 120]	7	20	0.233	0.667
(120, 130]	9	29	0.300	0.967
(130, 140]	1	30	0.033	1.000
Total	30	—	1.000	—

Cuadro 3: Tabla de frecuencia (altura dividida en intervalos irregulares)

²R representa la densidad de la frecuencia relativa

Para comprender mejor el gráfico de densidad que obtenemos con **R** (en Fig. 6), vamos a completar la tabla de frecuencias (Cuadro 3) añadiendo también las columnas x_i (marca de clase), a_i (amplitud del intervalo), h_i (densidad de frecuencia absoluta) y h'_i (densidad de frecuencia relativa).

Intervalo (mm)	n_i	N_i	f_i	F_i	x_i	a_i	h_i	h'_i
(85, 90]	1	1	0.033	0.033	87.5	5	0.200	0.0066
(90, 100]	7	8	0.233	0.267	95	10	0.700	0.0233
(100, 110]	5	13	0.167	0.433	105	10	0.500	0.0167
(110, 120]	7	20	0.233	0.667	115	10	0.700	0.0233
(120, 130]	9	29	0.300	0.967	125	10	0.900	0.0300
(130, 140]	1	30	0.033	1.000	135	10	0.100	0.0033
Total	30	—	1.000	—	—	—	—	—

R define las alturas de los rectángulos con la frecuencias **relativas**, es decir, utilizando la fórmula:

$$h'_i = \frac{f_i}{a_i} = \frac{n_i}{n \cdot a_i}$$

Esto asegura que el área total del histograma sea igual a 1.




Figura 6: Histograma y polígono de frecuencias de la altura de las plantas con intervalos irregulares en R

4.2.4. Código en R

```
#para datos cuantitativos continuos agrupados en intervalos:
hist(altura, breaks = extremos_intervalos, freq = FALSE, col = "lightblue",
     main = "Histograma de altura",
     xlab = "Altura (mm)")

h = hist(altura, breaks = extremos_intervalos, col = "lightblue",
        main = "Histograma de altura",
        xlab = "Altura (mm)")
lines(h$mids, h$density, type="l")
```

4.3. Cualitativas: diagrama de rectángulos y diagrama de sectores

Finalmente, nos centramos en el color de las hojas, es decir, una variable cualitativa.




Figura 7: Diagrama de rectángulos para el color de hojas.




Figura 8: Diagrama de sectores para el color de hojas.

4.3.1. Código en R

```
# Diagrama de rectángulos
col = df$Color
fAc = table(col)
barplot(fAc, col = c("khaki", "lightgreen", "darkgreen"), main = "Color de hojas",
        ylab = "Frecuencia abs")
```

```
#diagrama de sectores  
pie(fAc, col = c("khaki", "lightgreen", "darkgreen"))
```

Conclusión

Imagina que trabajas en una empresa y tu jefe te hace preguntas como: “¿Cuántas plantas hay que tienen exactamente 6 hojas?”, “¿Cuántas plantas tienen un número de hojas menor o igual a 7?” o, más en general, “¿Hay muchas plantas de color verde claro?”

Ahora vuelve a mirar la tabla con todos los datos (Cuadro 1), compárala por ejemplo con la Tabla 2 y el gráfico 1 o 8. Aunque toda la información estaba presente en la tabla 1, ¿no resulta mucho más fácil de entender (y de comunicar) al observar la tabla de frecuencias y los gráficos?

Con una buena visualización, incluso un jefe con prisa y que no conoce la definición de frecuencia absoluta o relativa puede hacerse una idea clara de las características de nuestras plantas de forma inmediata.

Así es como la estadística descriptiva nos ayuda a comprender y comunicar los datos.

TEMA 3

5. Medidas de localización y de dispersión

Imaginemos que queremos resumir brevemente la información de nuestros datos utilizando unas pocas medidas significativas. Por ejemplo, podríamos hacerlo para comparar la *Plantago lanceolata* con otro tipo de planta, o incluso para analizar las diferencias de esta misma especie en distintos hábitats.

Para ello, podemos recurrir a medidas de localización y de dispersión, que nos permiten sintetizar y comparar conjuntos de datos de manera efectiva.

En nuestro ejemplo de las plantas, supongamos que deseamos observar las diferencias en el número de hojas entre los hábitats H1 y H2. La siguiente tabla presenta estas medidas para cada hábitat y permite establecer una comparación entre ellos.

5.1. Número de hojas

Estadístico	H1	H2	Fórmula teórica
Media ($\bar{x}$)	8,73	6,20	$\bar{x} = \frac{1}{n} \sum x_i$
Moda	9	6	Valor con mayor frecuencia
Mediana	9	6	$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}}, & \text{si } n \text{ es impar} \\ \frac{1}{2}(x_{\frac{n}{2}} + x_{\frac{n}{2}+1}), & \text{si } n \text{ es par} \end{cases}$
Percentil 50	9	6	P_{50}
Cuartil Q1	7	5	$Q_1 = P_{25}$
Cuartil Q3	10	7	$Q_3 = P_{75}$
Rango	5	5	$R = x_{\max} - x_{\min}$
Rango intercuartílico	3	2	$IQR = Q_3 - Q_1$
Varianza	2,20	2,03	$s^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$
Desviación típica	1,48	1,42	$s = \sqrt{s^2}$
Coefficiente de variación	0,170	0,230	$CV = \frac{s}{\bar{x}}$

Cuadro 4: Resumen estadístico del número de hojas por hábitat (*Plantago lanceolata*).

5.2. Interpretacion

Podemos observar que:

En el hábitat 1:

- En promedio, una planta tiene 8.73 hojas.
- El número de hojas más frecuente es 9 (la mayoría de las plantas tienen 9 hojas).
- El 50 % de las plantas tienen como máximo 9 hojas.
- El 25 % de las plantas tienen como máximo 7 hojas.
- El 75 % de las plantas tienen como máximo 10 hojas.
- Los datos tienen una dispersion del 17 % respecto a la media

En el hábitat 2:

- En promedio, una planta tiene 6.2 hojas.

- la mayoría de las plantas tienen 6 hojas.
- El 50 % de las plantas tienen como máximo 6 hojas.
- El 25 % de las plantas tienen como máximo 5 hojas.
- El 75 % de las plantas tienen como máximo 7 hojas.
- Los datos tienen una dispersión del 23 % respecto a la media

Los datos sugieren que el hábitat tiene un impacto en el número de hojas: en la zona con alta humedad (hábitat 1), las plantas tienen más hojas

5.2.1. Código en R

```
# Filtra por habitat
plantas_H1 = subset(df, Habitat == "H1")
plantas_H2 = subset(df, Habitat == "H2")

# Media
mediaH1 = mean(plantas_H1$N_hojas)
mediaH1
mediaH2 = mean(plantas_H2$N_hojas)
mediaH2

# Moda
tH1 = table(plantas_H1$N_hojas)
which(tH1 == max(tH1))

tH2 <- table(plantas_H2$N_hojas)
which(tH2 == max(tH2))

# Mediana
median(plantas_H1$N_hojas)
median(plantas_H2$N_hojas)

# Percentil 50 (mediana con type = 2)
quantile(plantas_H1$N_hojas, 0.5, type = 2)
quantile(plantas_H2$N_hojas, 0.5, type = 2)

# Cuartiles
Q1_H1 = quantile(plantas_H1$N_hojas, 0.25, type = 2)
Q1_H1

Q3_H1 = quantile(plantas_H1$N_hojas, 0.75, type = 2)
Q3_H1

Q1_H2 = quantile(plantas_H2$N_hojas, 0.25, type = 2)
Q1_H2

Q3_H2 = quantile(plantas_H2$N_hojas, 0.75, type = 2)
Q3_H2

# Rango por hábitat
```

```

rango_H1 = max(plantas_H1$N_hojas) - min(plantas_H1$N_hojas)
rango_H2 = max(plantas_H2$N_hojas) - min(plantas_H2$N_hojas)
rango_H1
rango_H2

# Rango intercuartílico por hábitat
rango_intercuartilico_H1 = Q3_H1 - Q1_H1
rango_intercuartilico_H2 = Q3_H2 - Q1_H2
rango_intercuartilico_H1
rango_intercuartilico_H2

#Varianza
#¡Atención, que en R var(x) es la cuasivarianza!
nH1 = length(plantas_H1$N_hojas)
varianzaH1 = ((nH1 - 1) / nH1) * var(plantas_H1$N_hojas)
varianzaH1

nH2 = length(plantas_H2$N_hojas)
varianzaH2 = ((nH2 - 1) / nH2) * var(plantas_H2$N_hojas)
varianzaH2

# Desviación estándar
destipH1 = sqrt(varianzaH1)
destipH1
destipH2 = sqrt(varianzaH2)
destipH2

# Coeficiente de variación
destipH1 / abs(mediaH1)
destipH2 / abs(mediaH2)

```

6. Diagrama de caja y bigotes (o boxplot)

Podemos visualizar esta comparación también utilizando el diagrama de caja y bigotes (boxplot).

Para detectar posibles valores atípicos en el número de hojas, se aplicó el método del rango intercuartílico (IQR). Pore ejemplo, para todas las plantas (en azul en Fig 9) los cálculos fueron los siguientes:

- Primer cuartil (Q1): 6
- Tercer cuartil (Q3): 9
- Rango intercuartílico (IQR): $Q3 - Q1 = 9 - 6 = 3$
- Límite inferior: $Q1 - 1,5 \times IQR = 6 - 4,5 = 1,5$
- Límite superior: $Q3 + 1,5 \times IQR = 9 + 4,5 = 13,5$

Dado que todos los valores del número de hojas están dentro del rango $[1,5, 13,5]$, se concluye que **no hay outliers**. Todos los datos para el diagrama de caja por hábitat están presentes en la Tabla 4. Con cálculos sencillos se deduce que no hay valores atípicos (outliers) tampoco en

los datos divididos por hábitat. El diagrama de caja en la Figura 9 es útil para comparar la distribución de los datos entre hábitats y en relación con el conjunto total de datos.




Figura 9: Boxplot

6.0.1. Código en R

```
boxplot(df$N_hojas, plantas_H1$N_hojas, plantas_H2$N_hojas,
        names = c("All plants", "H1", "H2"),
        col = c("lightblue", "lightgreen", "lightpink"),
        main = "Boxplot del número de hojas",
        ylab = "Número de hojas")
```

7. Barras de error

Queremos representar la dispersión de los datos con respecto a la media según el hábitat. La representación gráfica es la siguiente:




Figura 10: Barras de error

7.0.1. Código en R

```
# Barras de error

medias = c(mediaH1, mediaH2)
desvTip = c(destipH1, destipH2)
medias
desvTip
# barplot
barCenters = barplot(medias, names.arg = c("H1", "H2"),
                      col = c("forestgreen", "goldenrod"),
                      ylim = c(0, max(medias + desvTip) + 10),
                      ylab = "N hojas media",
                      main = "N hojas media por habitat")

# Barras de error
arrows(x0 = barCenters, y0 = medias - desvTip,
       x1 = barCenters, y1 = medias + desvTip,
       angle = 90, code = 3, length = 0.1)
```

7.1. Entropía e índice de diversidad [Complemento]

Para datos cualitativos (como por ejemplo el color de las hojas), se mide la diversidad: es decir, cómo se distribuyen las frecuencias de las distintas opciones en relación unas con otras. Utilizamos el índice J para cuantificar esta diversidad.

Observa que $J = 0$ (sin diversidad) cuando existe un único valor con frecuencia relativa igual a 1 (es decir, en la muestra solo se observa una categoría). En cambio, $J = 1$ (diversidad máxima) cuando todos los valores aparecen una sola vez, es decir, tienen la misma frecuencia relativa. A partir de las frecuencias observadas para los colores de hojas, se calcularon los siguientes índices:

- **Entropía de Shannon** $H = 1,522$
- **Índice de diversidad** $J = \frac{H}{\log_2(N)} = \frac{1,522}{\log_2(30)} = 0,310$

Interpretación: Cuando el índice de diversidad J toma el valor 1, significa que la diversidad observada es máxima en relación con el número de opciones presentes. En nuestro caso, los índices sugieren una diversidad moderada de colores de hoja entre las plantas muestreadas.

7.1.1. Código en R

```
#primero instala vegan: install.packages("vegan")
library(vegan)

col
fAcol = table(col)
# Entropía de Shannon (base 2)
H = diversity(fAcol, index = "shannon", base = 2)
H

# Numero di categorie (k) e totale osservazioni (N)
k = length(fAcol)
```

```

N = sum(fAcol)

# Índices
D = H / log2(k)      # Índice de diversidad normalizado
D

J = H / log2(N)      # Índice de equitatividad (Pielou)
J

```

8. Medidas de forma

En esta sección queremos analizar la forma de la distribución de los datos, para ver si es simétrica o si, por ejemplo, puede aproximarse a una distribución normal. Lo hacemos en este caso utilizando la variable de la altura.

8.1. Simetria (skewness)

Primero queremos observar la simetría de la distribución con respecto a su media para la variable *altura*. Lo hacemos primero considerando todas las alturas del conjunto de datos, y luego analizamos la altura por cada hábitat por separado.

Para entender cuantitativamente si la distribución es simétrica o no, podemos utilizar el **coeficiente de simetría** (skewness). Para la altura en todo el conjunto de datos, dicho coeficiente es:

$$\gamma_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{n \cdot s^3} = -0,153$$

El valor de γ es negativo, lo que indica que la distribución está ligeramente sesgada a la izquierda (es decir, presenta una cola hacia la izquierda). Si representamos gráficamente los datos mediante un histograma, podemos observar esta asimetría también de forma visual.




Figura 11: histograma para todas las alturas del conjunto de datos: asim. izquierda

8.1.1. Código en R

```

n = length(altura)
media_h = mean(altura)
sd_h = sd(altura)

```

```

skewness = sum((altura - media_h)^3) / (n * sd_h^3)

print(paste("El coeficiente de simetria es:", round(skewness, 3)))

hist(altura, col = "lightblue", freq = FALSE,
     main = "Histograma de altura",
     xlab = "Altura (mm)")


```

A continuación, repetimos el análisis considerando los datos divididos por hábitat.


$$\gamma_{1H1} = 0,424$$

$$\gamma_{1H2} = 0,276$$

En este caso, el índice de simetría es mayor que cero, y efectivamente, cada una de las distribuciones individuales por hábitat está sesgada a la derecha.



(a) Distribución hábitat 1: asim. derecha



(b) Distribución hábitat 2: asim. derecha

Figura 12: Comparación de distribuciones de altura por hábitat

8.1.2. Código en R

```

#por habitat
altura_H1= df$Altura_mm[df$Habitat == "H1"]
n_H1 = length(altura_H1)
media_H1 = mean(altura_H1)
sd_H1 = sd(altura_H1)

skewness_H1 = sum((altura_H1 - media_H1)^3) / (n_H1 * sd_H1^3)

altura_H2= df$Altura_mm[df$Habitat == "H2"]
n_H2 = length(altura_H2)
media_H2 = mean(altura_H2)
sd_H2 = sd(altura_H2)

skewness_H2 = sum((altura_H2 - media_H2)^3) / (n_H2* sd_H2^3)

print(paste("El coeficiente de simetria por H1 es:", round(skewness_H1, 3)))
print(paste("El coeficiente de simetria por H2 es:", round(skewness_H2, 3)))

```

```
hist(altura_H1, col = "lightblue", freq = FALSE,
     main = "Histograma de altura H1",
     xlab = "Altura (mm)")

hist(altura_H2, col = "lightblue", freq = FALSE,
     main = "Histograma de altura H2",
     xlab = "Altura (mm)")
```

8.2. Curtosis

Este análisis se utiliza para entender si la distribución se asemeja a una normal. Dado que la distribución normal es simétrica, y hemos observado que la nuestra no lo es, esta parte resulta menos representativa de lo que podría ser con otros datos. Aun así, realizamos los cálculos para tener un ejemplo práctico del cálculo de la curtosis. El **coeficiente de curtosis** mide el grado de concentración de los datos en torno a la media y la presencia de colas extremas.

La fórmula del coeficiente de curtosis es:

$$\gamma_2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^4}{n \cdot S^4} - 3$$

Donde:

- x_i son los valores individuales (en nuestro caso las alturas)
- $\bar{x}$ es la media
- S es la desviación estándar
- n es el número de observaciones

Un valor de γ_2 cercano a 0 indica una curtosis similar a la distribución normal. Valores mayores indican colas más pesadas (leptocúrtica), mientras que valores menores indican colas más ligeras (platicúrtica).

En nuestro caso, el coeficiente de curtosis es de -1.373 para el conjunto total de alturas, -0.836 para el hábitat 1 y -0.891 para el hábitat 2. Estos valores negativos indican que las distribuciones son platicúrticas, es decir, presentan una forma más achatada que la distribución normal, con menos valores extremos y una menor concentración en las colas.

Grupo	Curtosis	Interpretación
Todas las alturas	-1.373	Distribución platicúrtica
Hábitat 1	-0.836	Moderadamente platicúrtica
Hábitat 2	-0.891	Similar al hábitat 1, también platicúrtica

Cuadro 5: Coeficientes de curtosis por grupo de datos

8.2.1. Código en R

```
curtosis = sum((altura - media_h)^4) / (n * sd_h^4) - 3

print(paste("El coeficiente de curtosis es:", round(curcrtosis, 3)))

curtosisH1 = sum((altura_H1 - media_H1)^4) / (n_H1 * sd_H1^4) - 3
curtosisH2 = sum((altura_H2 - media_H2)^4) / (n_H2 * sd_H2^4) - 3
print(paste("El coeficiente de curtosis por H1 es:", round(curcrtosisH1, 3)))
print(paste("El coeficiente de curtosis por H2 es:", round(curcrtosisH2, 3)))
```

TEMA 4

9. Análisis de relaciones entre dos características

Imaginemos ahora que queremos estudiar si existen relaciones entre las características de nuestras plantas. Por ejemplo: ¿hay una relación entre el color de las hojas y el hábitat en el que se encuentran? ¿Y entre la altura de la planta y el número de hojas?

En otras palabras, queremos examinar nuestro conjunto de datos no observando una sola característica de la planta, sino intentando comprender las posibles relaciones entre dos características.

9.1. Relación entre el color de las hojas y el hábitat

Por ejemplo, nos preguntamos si el color de las hojas está influenciado por el hábitat. Para investigarlo, comenzamos contando en nuestro conjunto de datos cuántas plantas del hábitat 1 tienen hojas de color amarillento, cuántas verde claro y cuántas verde oscuro. Hacemos lo mismo para el hábitat 2.

Organizamos esta información en una tabla, obteniendo así la **tabla de frecuencias absolutas conjunta**. Para nuestro conjunto de datos, la tabla es la siguiente:

	H1	H2
Amarillento	1	5
Verde claro	6	6
Verde oscuro	8	4

Cuadro 6: Frecuencias absolutas conjunta (color de hoja, hábitat)

Nótese que cada valor está comprendido entre 0 y el número total de observaciones. La frecuencia absoluta **marginal** es el número total de observaciones para un valor específico de una variable en una distribución bidimensional, sin considerar la otra variable. Para obtenerla, se suman las frecuencias absolutas de esa fila o columna en una tabla de doble entrada, lo que resalta la distribución individual de cada variable por separado. En nuestro caso por ejemplo la frecuencia absoluta **marginal** de amarillento es $(1+5 =) 6$; de verde claro es $(6+6 =) 12$ y de verde oscuro es $(8+4 =) 12$. La frecuencia absoluta **marginal** del hábitat 1 es $(1+6+8 =) 15$ y la frecuencia absoluta **marginal** del hábitat 2 es $(5+6+4 =) 15$.

Podemos observar que hay pocas plantas con hojas amarillentas en el hábitat 1 (solo 1), mientras que en el hábitat 2 hay 5. Esto sugiere que podría existir una relación entre el color de las hojas y el hábitat en el que se encuentran.³

La tabla de frecuencias absolutas necesita que el lector tenga una idea del número total de observaciones. Por ejemplo, imagina haber registrado 1 planta con hojas amarillentas en el hábitat H1 dentro de una muestra de 10 observaciones, o haber registrado esa misma planta en una muestra de 100. El valor en la tabla absoluta sería el mismo, pero su significado estadístico sería diferente: en el segundo caso, el color amarillento sería mucho más raro.

Para capturar esta información en una sola tabla, se utiliza la **frecuencia relativa conjunta**, que indica la proporción de veces que se observa cada combinación de características.

En el Cuadro 7 se muestra la tabla de frecuencias relativas conjuntas para nuestros datos.

Nótese que ahora cada valor está comprendido entre 0 y 1. El valor 0.0333 para amarillento en H1 significa que el 3.33 % del total de las observaciones corresponde a plantas con hojas amarillentas en el hábitat H1. La frecuencia relativa **marginal** de amarillento es $(0.0333 + 0.1667 =) 0.2$; de verde claro es $(0.2 + 0.2 =) 0.4$ y de verde oscuro es $(0.2667 + 0.1333 =) 0.4$.

³Para confirmar esta intuición, sería conveniente registrar más datos, ya que un mayor volumen de observaciones permite obtener estadísticas más fiables.

	H1	H2
Amarillento	0.0333	0.1667
Verde claro	0.2000	0.2000
Verde oscuro	0.2667	0.1333

Cuadro 7: Frecuencia relativa conjunta del color de hoja por hábitat

La frecuencia relativa **marginal** del habitat 1 es $(0.0333 + 0.2 + 0.2667 =) 0.5$ y la frecuencia relativa **marginal** del habitat 2 es $(0.1667 + 0.2 + 0.1333 =) 0.5$.

9.1.1. Código en R

```
# DISTRIBUCION CONJUNTA
```

```
conjunta = table(df$Color, df$Habitat)
conjunta
```

```
rel_conjunta = prop.table(conjunta)
rel_conjunta
```

9.1.2. Análisis de distribuciones condicionadas

Imaginemos que un colega nos trae dos plantas, pero no ha anotado de qué hábitat las ha tomado. Podemos observar que las hojas de una planta son *amarillentas* y las de la otra son *verde oscuro*.

¿Cuál es la probabilidad de que la primera planta provenga del hábitat 1? ¿Y cuál es la probabilidad de que la segunda planta (con hojas verde oscuro) sea del hábitat 1?

Para responder a estas preguntas, utilizamos las distribuciones condicionadas, es decir, buscamos la probabilidad de que una planta pertenezca al hábitat 1 dado que sabemos el color de sus hojas.

La probabilidad de que una planta con hojas **amarillentas** pertenezca al hábitat **1** es:

$$f_{H1|X = \text{amarillento}} = \frac{\text{Número de plantas amarillentas en H1}}{\text{Total de plantas amarillentas}} = 0,1667$$

Igualmente la probabilidad de que una planta con hojas **verde oscuro** pertenezca al hábitat **1** es

$$f_{H1|X = \text{verde oscuro}} = \frac{\text{Número de plantas verde oscuro en H1}}{\text{Total de plantas oscuras}} = \frac{8}{12} = 0,6667$$

A continuación se muestra la tabla de frecuencias relativas del hábitat condicionada al color de las hojas:

Color	H1	H2
Amarillento	0.1667	0.8333
Verde claro	0.5000	0.5000
Verde oscuro	0.6667	0.3333

Con probabilidad 83.33 % la primera planta pertenece a H2.

9.1.3. Código en R

```
# DISTRIBUCION CONDIZIONADAS
# prop.table(table(x,y),a)
# with a = to 1 if it is y condicional to x, 2 for x condicional to x

conjunta = table(df$Color, df$Habitat)
prop.table(conjunta,1) #habitat condicionado al color
```

9.2. Relación entre la altura (agrupada) y el numero de hojas

Con las mismas herramientas podemos analizar la relación entre la **altura** de la planta y el **número de hojas**. La altura es una variable continua, por lo que preferimos agruparla en intervalos de 10 mm.

También en este caso comenzamos calculando la tabla de frecuencias absolutas conjuntas y la tabla de frecuencias relativas conjuntas. A continuación se presentan ambas tablas para nuestros datos:

Intervalos	4	5	6	7	8	9	10	11
(80,90]	1	0	0	0	0	0	0	0
(90,100]	1	2	3	1	0	0	0	0
(100,110]	0	1	1	1	2	0	0	0
(110,120]	0	0	0	2	0	3	1	1
(120,130]	0	0	0	2	2	2	2	1
(130,140]	0	0	1	0	0	0	0	0

Cuadro 8: Frecuencias absolutas conjuntas

Intervalos	4	5	6	7	8	9	10	11
(80,90]	0.0333	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
(90,100]	0.0333	0.0667	0.1000	0.0333	0.0000	0.0000	0.0000	0.0000
(100,110]	0.0000	0.0333	0.0333	0.0333	0.0667	0.0000	0.0000	0.0000
(110,120]	0.0000	0.0000	0.0000	0.0667	0.0000	0.1000	0.0333	0.0333
(120,130]	0.0000	0.0000	0.0000	0.0667	0.0667	0.0667	0.0667	0.0333
(130,140]	0.0000	0.0000	0.0333	0.0000	0.0000	0.0000	0.0000	0.0000

Cuadro 9: Frecuencias relativa conjuntas

Que te parece, ¿existe una relación entre altura y número de hojas?

9.2.1. Código en R

```
# DISTRIBUCION CONJUNTA

altura = df$Altura_mm
n_hojas = df$N_hojas
extremos_intervalos= c(80, 90, 100, 110, 120, 130, 140)
```

```
intervalos = cut (altura, extremos_intervalos)
conjunta_hh = table(intervalos, n_hojas)
conjunta_hh
```

```
rel_conjunta_hh = prop.table(conjunta_hh)
rel_conjunta_hh
```

10. Visualización de la relación entre dos características

Siempre es más fácil hacer observaciones después de haber visualizado los datos. Para analizar la relación entre dos características, podemos utilizar una **nube de puntos** o **diagrama de dispersión**.

Este tipo de gráfico representa visualmente cómo se distribuyen los datos en función de dos variables, permitiendo identificar patrones, tendencias o posibles correlaciones.

La siguiente figura muestra el diagrama de dispersión entre la **altura de la planta** y el **número de hojas**:




Figura 13: Diagrama de dispersión o nube de puntos (scatterplot)

Y ahora, al observar el gráfico, ¿te parece que existe una relación? Si es así, ¿por qué?

10.0.1. Código en R

```
# DIAGRAMA DE DISPERSION
altura = df$Altura_mm
n_hojas = df$N_hojas
plot(n_hojas, altura)
```

11. Dependencia funcional e Independencia

En este apartado analizamos si existe una relación de dependencia funcional o independencia entre las variables **altura de la planta** (X) y **número de hojas** (Y), basándonos en los datos recogidos.

11.1. Dependencia funcional

Diremos que Y depende funcionalmente de X si existe una función f tal que $Y = f(X)$, es decir, a cada valor de altura le corresponde un único número de hojas.

Al observar la tabla de frecuencias absolutas conjuntas, notamos que para un mismo intervalo de altura aparecen múltiples valores distintos de número de hojas. Por ejemplo, en el intervalo $(120, 130]$ hay plantas con 7, 8, 9, 10 y 11 hojas.

Esto indica que **no existe una dependencia funcional** entre altura y número de hojas, ya que a un mismo valor de X le corresponden varios valores de Y.

11.2. Independencia estadística

Diremos que las variables X e Y son independientes si la distribución de X no depende de los valores de Y. Esto se traduce en que las frecuencias relativas conjuntas deben cumplir:

$$f_{ij} = f_{i\cdot} \cdot f_{\cdot j} \quad \text{para todo } i, j$$

O bien, en términos de frecuencias absolutas:

$$n_{ij} = \frac{n_{i\cdot} \cdot n_{\cdot j}}{n} \quad \text{para todo } i, j$$

Si calculamos, por ejemplo, las frecuencias absolutas marginales $n_{i\cdot}$ para $i = 1$ (altura $(80, 90]$) y $n_{\cdot j}$ para $j = 1$ (4 hojas), obtenemos que $n_{1\cdot} = 1$ y $n_{\cdot 1} = 2$.

Recuerda que estos valores se calculan desde la tabla de frecuencias absoluta:

Frecuencias absolutas conjuntas

Intervalos	4	5	6	7	8	9	10	11
(80,90]	1	0	0	0	0	0	0	0
(90,100]	1	2	3	1	0	0	0	0
(100,110]	0	1	1	1	2	0	0	0
(110,120]	0	0	0	2	0	3	1	1
(120,130]	0	0	0	2	2	2	2	1
(130,140]	0	0	1	0	0	0	0	0

La frecuencia absoluta marginal de la altura $(80,90]$ $n_{1\cdot}$ se calcula sumando los valores dentro del cuadrado rojo (fila 1). La frecuencia absoluta marginal del número de hojas 4 $n_{\cdot 1}$ se obtiene sumando los valores dentro del cuadrado verde (columna 1). n es el número total de observaciones. El valor n_{11} corresponde al valor en azul dentro de la tabla de frecuencias absolutas.

Entonces, $n_{11} = 1$, lo cual es diferente de $\frac{1 \cdot 2}{30} = 0,0666$.

Como existe al menos una pareja (i, j) que no satisface la ecuación anterior (por ejemplo $(80, 90], 4$), las variables no son independientes.

En R, se puede calcular la tabla completa de valores esperados bajo independencia usando la fórmula:

$$n_{ij}^{\text{esperado}} = \frac{n_{i\cdot} \cdot n_{\cdot j}}{n}$$

para todos los valores de i, j (Cuadro 10). Al comparar esta tabla con la Cuadro 9 (frecuencias observadas), se observa que existen celdas donde los valores difieren, lo que indica que las variables **no son independientes**.

	4	5	6	7	8	9	10	11
(80,90]	0.0667	0.1	0.1667	0.2	0.1333	0.1667	0.1	0.0667
(90,100]	0.4667	0.7	1.1667	1.4	0.9333	1.1667	0.7	0.4667
(100,110]	0.3333	0.5	0.8333	1.0	0.6667	0.8333	0.5	0.3333
(110,120]	0.4667	0.7	1.1667	1.4	0.9333	1.1667	0.7	0.4667
(120,130]	0.6000	0.9	1.5000	1.8	1.2000	1.5000	0.9	0.6000
(130,140]	0.0667	0.1	0.1667	0.2	0.1333	0.1667	0.1	0.0667

Cuadro 10: Tabla de frecuencias esperadas bajo independencia

A continuación se muestra el código en R utilizado

11.2.1. Código en R

```
altura = df$Altura_mm
n_hojas = df$N_hojas
extremos_intervalos= c(80, 90, 100, 110, 120, 130, 140)
intervalos = cut (altura, extremos_intervalos)
conjunta_hh = table(intervalos, n_hojas)
conjunta_hh

rel_conjunta_hh = prop.table(conjunta_hh)
rel_conjunta_hh

frecuencia_marginal_altura = rowSums(conjunta_hh)
frecuencia_marginal_altura
frecuencia_marginal_nhojas = colSums(conjunta_hh)
frecuencia_marginal_nhojas
n = sum(conjunta_hh)
n

nij_esp = outer(frecuencia_marginal_altura, frecuencia_marginal_nhojas,
                FUN = function(fi, fj) (fi * fj) / n)
nij_esp
```

Según los datos analizados, no se observa una dependencia funcional entre altura y número de hojas, pero sí se detecta una **dependencia estadística**, lo que indica que existe una relación entre ambas variables: las plantas más altas tienden a tener más hojas.

12. Covarianza

Para estudiar la relación entre la altura y el número de hojas, también podemos calcular la covarianza. En nuestro caso,

$$S_{X,Y} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{30} \sum_{i=1}^{30} (x_i - 113,3)(y_i - 7,2) \approx 17,89$$

por lo tanto la covarianza es positiva, es decir, cuantas más hojas tiene la planta, mayor es su altura. Este comportamiento se aprecia claramente en la Figura 14.

12.0.1. Código en R

```
((n - 1) / n) * cov(n_hojas, altura)
```

13. Hacemos predicciones: recta de regresión lineal

Ahora que hemos aprendido mucho a partir de nuestros datos utilizando herramientas estadísticas, podemos dar un paso más y comenzar a hablar de predicciones.

En este curso abordamos un método de predicción sencillo: la **regresión lineal**. Sin embargo, existen muchos otros métodos, incluso más complejos, que permiten hacer predicciones basadas en lo que se ha aprendido de los datos. El *machine learning* es un ejemplo más avanzado de los mismos conceptos que aquí vemos en su forma básica (de hecho, algunos han llamado al *machine learning* una “estadística glorificada”).

Primero hemos observado que existe una correlación entre la **altura de las plantas** y el **número de hojas**. Esto nos permite intentar estimar, por ejemplo, la altura de una planta que tiene 12 hojas. Intuitivamente, podemos imaginar que será alta, ya que tiene muchas hojas (covarianza positiva). Pero si nos pidieran un número preciso para su altura, ¿qué podríamos responder?

Para estimar la altura de una planta con 12 hojas que no hemos visto antes en nuestro conjunto de datos, quisiéramos encontrar una función h tal que:

$$\text{altura} = h(n_{\text{hojas}})$$

Teniendo esta función, podríamos calcular fácilmente la altura de esta nueva planta como $h(12)$.

En este curso, imaginamos que estimamos la función h mediante una recta:

$$h(x) = a + bx \quad \text{con } x = n_{\text{hojas}}$$

Ahora bien, ¿cómo estimamos esta recta?

La intuición es que queremos cometer el menor error posible, es decir, si tenemos un dato registrado y_i , queremos que nuestra estimación $h(x_i)$ esté lo más cerca posible de y_i , y deseamos que esto ocurra (idealmente) para todos los datos.

Expresamos esta idea buscando los valores de a y b que minimicen la siguiente función de error:

$$F(a, b) = \sum_{i=1}^n (y_i - h(x_i))^2 = \sum_{i=1}^n (y_i - a - bx_i)^2$$

Para ello, se deriva $F(a, b)$ con respecto a a y b y se iguala a 0 (ver A), obteniéndose

$$\begin{cases} a = \bar{y} - b\bar{x} \\ b = \frac{S_{xy}}{S_x^2} \end{cases}$$

Interpretación:

- b representa la pendiente de la recta: cuánto cambia y por cada unidad de cambio en x .

- a es la ordenada al origen: el valor estimado de y cuando $x = 0$.

Estos coeficientes definen la recta de regresión que mejor se ajusta a los datos en el sentido de mínimos cuadrados.

Para nuestros datos:

$$\bar{y} = 112,4 \quad (\text{media de alturas})$$

$$\bar{x} = 7,467 \quad (\text{media del número de hojas})$$

$$S_{xy} = 18,52 \quad (\text{covarianza entre número de hojas y altura})$$

$$S_x^2 = 3,84 \quad (\text{varianza del número de hojas})$$

De aquí se deriva el coeficiente de regresión:

$$b = \frac{S_{xy}}{S_x^2} = \frac{18,52}{3,84} = 4,817$$

Y el término independiente:

$$a = \bar{y} - b \cdot \bar{x} = 112,4 - 4,817 \cdot 7,467 = 76,43$$

En R, esto se puede calcular realizando los cálculos estadísticos manualmente o utilizando la función `lm` (ajuste de modelo lineal). También podemos representar gráficamente el resultado, lo que nos da una idea visual de nuestra recta de regresión.




Figura 14: Diagrama de dispersión y recta de regresion

Ahora estamos finalmente listos para hacer nuestra predicción: ¿cuánto medirá la nueva planta que tiene 12 hojas?

$$a + b \cdot 12 = 76,43 + 4,817 \cdot 12 = 134,2356 \text{ mm}$$

13.0.1. Código en R

```
recta_regresion = lm(altura ~ n_hojas) #fit linear model
recta_regresion

a = recta_regresion$coefficients[1]
b = recta_regresion$coefficients[2]
a
b

# representacion grafica
plot(n_hojas, altura)
abline(recta_regresion, col = "red")
```

Para evaluar cuán fiable es nuestra recta de regresión lineal, calculamos el coeficiente de correlación lineal r .

$$r = \frac{S_{xy}}{S_x S_y} = 0,715$$

Como criterio, en el ámbito de la ingeniería se considera que la recta es buena si $r^2 > 0,75$. En nuestro caso, $r^2 = 0,5116$, por lo tanto el ajuste no es muy bueno.

Sin embargo, cabe señalar que estos intervalos no son estrictos. En biología, la variabilidad natural suele ser elevada, por lo que incluso un valor de $r^2 = 0,5$ puede considerarse significativo.

13.0.2. Código en R

```
r = cor(n_hojas, altura)
r^2
```

A. Cálculo de los coeficientes de la regresión lineal [COMPLEMENTO]

Queremos encontrar los valores de a y b que minimizan la función de error cuadrático:

$$F(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2$$

Para ello, derivamos parcialmente con respecto a a y b , y resolvemos el sistema de ecuaciones que se obtiene al igualar las derivadas a cero.

A.1. Derivada parcial con respecto a a

$$\frac{\partial F}{\partial a} = \sum_{i=1}^n 2(y_i - a - bx_i)(-1) = -2 \sum_{i=1}^n (y_i - a - bx_i)$$

Igualamos a cero:

$$\sum_{i=1}^n (y_i - a - bx_i) = 0$$

$$\sum y_i - na - b \sum x_i = 0$$

$$na + b \sum x_i = \sum y_i \quad (1)$$

A.2. Derivada parcial con respecto a b

$$\frac{\partial F}{\partial b} = \sum_{i=1}^n 2(y_i - a - bx_i)(-x_i) = -2 \sum_{i=1}^n x_i(y_i - a - bx_i)$$

Igualamos a cero:

$$\sum x_i(y_i - a - bx_i) = 0$$

$$\sum x_i y_i - a \sum x_i - b \sum x_i^2 = 0$$

$$a \sum x_i + b \sum x_i^2 = \sum x_i y_i \quad (2)$$

A.3. Resolviendo el sistema

Usamos las ecuaciones (1) y (2) para resolver el sistema lineal:

$$\begin{cases} na + b \sum x_i = \sum y_i \\ a \sum x_i + b \sum x_i^2 = \sum x_i y_i \end{cases}$$

Resolviendo este sistema obtenemos:

$$b = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2}$$

$$a = \frac{\sum y_i - b \sum x_i}{n}$$